

Universidad Tecnológica de Pereira
Facultad de Ingenierías
Programa de Ingeniería Electrónica

Comparación entre Random Forest y Support Vector Machines en Problemas de Ingeniería

Examen 2 — Inteligencia Artificial

Asignatura: Inteligencia Artificial
Docente: German A. Holguín L.
Entrega: Mayo 2026
Grupo: Belsy Jhossira Mena Rentería
Daniel Restrepo Ocampo
Carlos Mario Carretero Castillo

1. Descripción del Problema

Los sistemas fotovoltaicos modernos forman parte del paradigma de la Industria 4.0, en el cual la instrumentación continua y el análisis de datos en tiempo real son indispensables para garantizar la operación eficiente y el mantenimiento predictivo. La capacidad de diagnosticar automáticamente la condición operativa y de predecir la potencia generada tiene alto valor práctico: permite detectar fallas de manera temprana y planificar mantenimiento proactivo sin inspección física permanente.

El problema se descompone en dos tareas de aprendizaje supervisado:

Problema 1 — Clasificación La condición operativa (`condition`) es categórica con cinco valores: *normal*, *sombreado parcial*, *suciedad*, *falla de panel* y *falla de inversor*:

$$\hat{c} = f_{\theta}(\mathbf{x}), \quad \hat{c} \in \{\text{normal, sombreado_parcial, suciedad, falla_panel, falla_inversor}\} \tag{1}$$

Problema 2 — Regresión La potencia generada (`power_W`) es continua; se aprende un mapeo desde variables ambientales hasta la potencia esperada:

$$\hat{P} = g_{\theta}(\mathbf{x}), \quad \hat{P} \in \mathbb{R}^+ \tag{2}$$

2. Simulación del Conjunto de Datos

2.1 Parámetros físicos y variables ambientales

Cuadro 1: Parámetros físicos del sistema fotovoltaico simulado.

Símbolo	Descripción	Valor	Unidad
η	Eficiencia del panel	0.18	adimensional
A	Área del arreglo fotovoltaico	20.0	m ²
NOCT	Temperatura nominal de operación	45.0	°C
γ	Coefficiente de temperatura	−0,004	°C ^{−1}
G_{max}	Irradiancia máxima	1000	W/m ²
V_{OC}	Voltaje de circuito abierto	380.0	V

Las variables ambientales se generaron con distribuciones físicamente razonables: `hour` $\sim U[6, 20]$ h; `day_of_year` $\sim U[1, 365]$; `ambient_temp_C` $\sim \mathcal{N}(25, 6^2)$ recortada a $[5, 45]$ °C; `humidity_percent` $\sim U[20, 90]$ %; `wind_speed_m_s` $\sim \text{Exp}(3)$ recortada a $[0, 15]$ m/s.

2.2 Modelos físicos

La irradiancia incorpora variación estacional y perfil diario:

$$G(t, d) = G_{\max} \left[1 + 0,1 \sin \frac{2\pi(d-80)}{365} \right] \sin \frac{\pi(t-6)}{14} + \epsilon_G, \quad \epsilon_G \sim \mathcal{N}(0, 20^2) \quad (3)$$

La temperatura del panel sigue la ecuación NOCT:

$$T_{\text{panel}} = T_{\text{amb}} + \frac{\text{NOCT} - 20}{800} G + \epsilon_T, \quad \epsilon_T \sim \mathcal{N}(0, 1,5^2) \text{ } ^\circ\text{C} \quad (4)$$

La potencia eléctrica de salida se calcula como:

$$P = \eta \cdot A \cdot G_{\text{eff}} \cdot [1 + \gamma(T_{\text{panel}} - 25)] \cdot f_{\text{falla}} + \epsilon_P, \quad \epsilon_P \sim \mathcal{N}(0, 10^2) \text{ W} \quad (5)$$

2.3 Condiciones operativas

Cuadro 2: Condiciones operativas simuladas ($n = 5000$).

Condición	Prob.	Muestras	f_{falla} mín.	f_{falla} máx.
Normal	50 %	2507	0.95	1.00
Sombreado parcial	20 %	1003	0.40	0.70
Suciedad	15 %	733	0.70	0.90
Falla de panel	10 %	516	0.10	0.40
Falla de inversor	5 %	241	0.00	0.05




Figura 1: Distribución de clases en el dataset sintético ($n = 5000$). El desbalance refleja proporciones típicas de falla en un sistema fotovoltaico real.

3. Prevención de Fuga de Información

Cuadro 3: Variables excluidas por problema para prevenir fuga de información.

Problema	Variable objetivo	Variables excluidas como entrada
Clasificación	condition	condition (es la etiqueta); power_W (evita dependencia cruzada entre tareas)
Regresión	power_W	power_W; condition (codifica implícitamente f_{falla}); voltage_V y current_A (predicción trivial $P \approx V \cdot I$)

Variables de entrada efectivas: **Clasificación** — 9 variables: hour, day_of_year, irradiance_W_m2, ambient_temp_C, panel_temp_C, humidity_percent, wind_speed_m_s, voltage_V, current_A. **Regresión** — 7 variables: las mismas excepto voltage_V y current_A.

4. Entrenamiento de Modelos

El dataset (5000 muestras) se dividió 80/20 (entrenamiento/prueba). Para clasificación se usó partición estratificada (`stratify=y`); para regresión KFold estándar. Se aplicó **StandardScaler** exclusivamente sobre el conjunto de entrenamiento para SVM/SVR, ya que el kernel RBF calcula distancias euclidianas y es sensible a la escala. Random Forest no requiere escalado al basar sus decisiones en umbrales ordinales.

Se seleccionó el **kernel RBF** por la naturaleza no lineal de las relaciones entre variables ambientales y salidas del sistema: $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$. La hiperparametrización se realizó con **RandomizedSearchCV** (8 iteraciones, CV=5).

Cuadro 4: Mejores hiperparámetros encontrados para cada modelo.

Modelo	Mejores hiperparámetros
RFC	n_estimators=300, max_depth=20, min_samples_split=2, max_features=sqrt
SVC	C=100.0, gamma=auto, kernel=rbf
RFR	n_estimators=200, max_depth=10, min_samples_split=5, max_features=sqrt
SVR	C=10.0, gamma=scale, epsilon=1.0, kernel=rbf

5. Métricas de Evaluación

5.1 Clasificación

Cuadro 5: Métricas globales de clasificación (conjunto de prueba: 1000 muestras).

Modelo	Accuracy (test)	CV-5 (media)	CV-5 (σ)
Random Forest Classifier	0.8920	0.8925	0.0082
Support Vector Classifier	0.9250	0.9158	0.0062

Cuadro 6: Precision, Recall y F1-score por clase — conjunto de prueba.

Clase	Random Forest			SVC		
	Prec.	Recall	F1	Prec.	Recall	F1
Falla inversor	1.00	1.00	1.00	1.00	1.00	1.00
Falla panel	0.95	0.84	0.89	0.88	0.83	0.86
Normal	0.88	1.00	0.93	0.94	0.98	0.96
Sombreado parcial	0.86	0.88	0.87	0.89	0.92	0.90
Suciedad	0.92	0.55	0.69	0.93	0.80	0.86
Macro avg	0.92	0.85	0.88	0.93	0.90	0.92
Weighted avg	0.90	0.89	0.88	0.92	0.93	0.92




Figura 2: Matrices de confusión normalizadas por fila para RFC (izquierda) y SVC (derecha).




Figura 3: Importancia de variables (criterio Gini) para el RandomForestClassifier.

5.2 Regresión

Cuadro 7: Métricas de regresión — conjunto de prueba (1000 muestras).

Modelo	MAE (W)	RMSE (W)	R ²	CV-5 R ² (media)	CV-5 (σ)
Random Forest Regressor	516.0	674.5	0.5125	0.5139	0.0148
SVR	520.7	702.7	0.4709	0.4712	0.0196




Figura 4: Evaluación de regresión: valores reales vs predichos (fila superior) y residuos (fila inferior) para RFR (izquierda) y SVR (derecha).




Figura 5: Importancia de variables para el RandomForestRegressor. La irradiancia solar domina ampliamente la predicción de potencia.

6. Comparación Crítica

Clasificación. El SVC obtuvo accuracy de 0.9250, superando al RFC (0.8920) en 3.3 puntos. La diferencia es más pronunciada en la clase *suciedad* (recall: 0.55 RFC vs. 0.80 SVC): el kernel RBF captura mejor las fronteras de decisión entre condiciones sutiles con solapamiento en el espacio de características.

Regresión. El RFR supera al SVR en todas las métricas (R^2 : 0.513 vs. 0.471). Los valores moderados de R^2 (≈ 0.5) son esperables: se excluyeron voltaje y corriente para evitar la predicción trivial $P \approx V \cdot I$, lo que aumenta la dificultad intrínseca del problema.

Escalado e interpretabilidad. El escalado con StandardScaler es crítico para SVM/SVR (sin escalado: SVC accuracy = 0.665, SVR R^2 = 0.434) pero irrelevante para Random Forest, que opera sobre umbrales ordinales. Random Forest es significativamente más interpretable: ofrece importancia nativa de variables y parámetros con semántica directa, mientras que SVM opera en un espacio de Hilbert de dimensión potencialmente infinita.

Sensibilidad a hiperparámetros. SVM/SVR es marcadamente más sensible: el accuracy de SVC oscila 42 puntos porcentuales al variar C de 0.01 a 100; el R^2 del SVR pasa de valores negativos a 0.47. Random Forest es robusto en un rango amplio.




Figura 6: Sensibilidad al hiperparámetro C para SVC (accuracy) y SVR (R^2). Valores pequeños producen subajuste severo; la saturación ocurre en $C \approx 10$ – 100 .

Variables más importantes. En clasificación, corriente (`current_A`) y voltaje (`voltage_V`) son las más discriminativas, lo que es físicamente coherente con la manifestación directa de fallas en parámetros eléctricos. En regresión, la irradiancia solar domina (importancia $\gg 0,5$), seguida de la temperatura del panel; humedad y viento tienen importancia casi nula.

Limitaciones y mejoras. Las principales limitaciones del dataset sintético son: (1) ausencia de correlaciones temporales; (2) modelos físicos lineales de primer orden; (3) desbalance de clase *falla de inversor* (5 %); (4) ruido gaussiano homoscedástico. Como mejoras se propone incorporar series temporales con procesos AR, modelos de doble diodo para la curva I-V, degradación temporal del panel y ruido correlacionado entre sensores.

7. Resumen de Resultados

Cuadro 8: Resumen comparativo de los cuatro modelos entrenados.

Problema	Modelo	Métrica 1	Métrica 2	CV (media $\pm \sigma$)
Clasificación	RFC	Acc = 0.892	F1 macro = 0.88	0,8925 $\pm$ 0,0082
	SVC	Acc = 0.925	F1 macro = 0.92	0,9158 $\pm$ 0,0062
Regresión	RFR	RMSE = 674.5 W	R² = 0.513	0,5139 $\pm$ 0,0148
	SVR	RMSE = 702.7 W	R ² = 0.471	0,4712 $\pm$ 0,0196

Conclusiones principales

El Support Vector Classifier con kernel RBF demostró ser el modelo más adecuado para el diagnóstico de la condición operativa del sistema fotovoltaico, alcanzando un accuracy de 0.925 frente al 0.892 del Random Forest Classifier. La diferencia más significativa se observó en la clase *suciedad*, donde el SVC logró un recall de 0.80 frente al 0.55 del RFC. Esto indica que el hiperplano de separación en el espacio transformado por el kernel RBF captura con mayor precisión las fronteras de decisión entre condiciones operativas con solapamiento en el espacio de características, haciendo del SVC la opción preferida cuando la correcta identificación de fallas sutiles es prioritaria.

Para la predicción de potencia generada, el Random Forest Regressor superó al SVR en todas las métricas evaluadas, obteniendo un R^2 de 0.513 frente a 0.471 y un RMSE de 674.5 W frente a 702.7 W. Los valores moderados de R^2 ($\approx 0,5$) son un resultado esperado y metodológicamente correcto: al excluir el voltaje y la corriente como variables de entrada se eliminó la posibilidad de la predicción trivial $P \approx V \cdot I$, lo que aumenta la dificultad intrínseca del problema y obliga a los modelos a aprender la física del sistema a partir exclusivamente de las condiciones ambientales.

Desde una perspectiva práctica de ingeniería, Random Forest se consolida como el modelo más robusto e interpretable de los evaluados: no requiere escalado de variables, ofrece importancia nativa de características y mantiene un desempeño estable ante variaciones amplias en sus hiperparámetros. SVM y SVR, en contraste, son altamente sensibles al parámetro C y exigen escalado previo obligatorio para funcionar correctamente. El análisis de importancia de variables reveló además que la irradiancia solar es el predictor dominante en regresión, mientras que la corriente y el voltaje son las variables más discriminativas en clasificación, resultado coherente con la física del sistema fotovoltaico instrumentado.

Repositorio

El código fuente, el dataset sintético y los resultados del experimento están disponibles en el siguiente repositorio de GitHub:

[https://github.com/CarlosMarioCarreteroCastillo/
An-lisis-Predictivo-en-Sistemas-Fotovoltaicos-Random-Forest-vs.-SVM](https://github.com/CarlosMarioCarreteroCastillo/An-lisis-Predictivo-en-Sistemas-Fotovoltaicos-Random-Forest-vs.-SVM)